

# Méthodes d'Optimisation Numérique Appliquées au Dataset California Housing

Nom et Prénom: Fatimetou/limam/Abeid  
C16698

Université de NKT

MiniProjet 2026

# Plan

- 1 Introduction
- 2 Dataset California Housing
- 3 Phase 1 — Gradient déterministe
- 4 Phase 2 — Gradient stochastique
- 5 Phase 3 — Méthodes proximales
- 6 Résultats expérimentaux
- 7 Conclusion

# Objectifs du projet

- Étudier les méthodes d'optimisation vues aux Chapitres 1 à 4
- Comparer :
  - Gradient déterministe
  - Gradient stochastique
  - Méthodes adaptatives
  - Méthodes proximales
- Application sur des données réelles
- Analyse des courbes Perte vs Temps

# Présentation du dataset

- Recensement Californie – 1990
- Données agrégées par district
- Variables socio-économiques :
  - Revenu médian
  - Âge des logements
  - Population
  - Nombre de pièces
- Cible : valeur médiane des maisons

- Transformation en classification binaire :

$$y_i = \begin{cases} +1 & \text{si MedHouseVal} > \text{médiane} \\ -1 & \text{sinon} \end{cases}$$

- Standardisation des variables
- Dimension :  $n \times d$

$$F(w) = \frac{1}{n} \sum_{i=1}^n \log \left( 1 + e^{-y_i x_i^T w} \right) + \frac{\lambda}{2} \|w\|^2$$

- Perte logistique
- Régularisation L2 (Ridge)

- $F \in C^2(\mathbb{R}^d)$
- Fonction convexe
- $\lambda$ -fortement convexe :

$$\nabla^2 F(w) \succeq \lambda I_d$$

- Existence et unicité du minimiseur

$$\nabla F(w) = -\frac{1}{n} \sum_{i=1}^n \frac{y_i x_i}{1 + e^{y_i x_i^T w}} + \lambda w$$

$$L = \frac{1}{4n} \|X\|_2^2 + \lambda$$

- Pas de gradient :  $\alpha \leq \frac{1}{L}$
- Convergence linéaire



# Pourquoi SGD ?

- Gradient complet :  $\mathcal{O}(nd)$
- SGD :  $\mathcal{O}(d)$
- Adapté aux grands jeux de données
- Mise à jour aléatoire

$$w_{k+1} = w_k - \alpha_k \left( -\frac{y_{i_k} x_{i_k}}{1 + e^{y_{i_k} x_{i_k}^T w_k}} + \lambda w_k \right)$$
$$\alpha_k = \frac{\alpha_0}{1 + k}$$

- RMSPProp :
  - Normalisation adaptative
  - Réduction de variance
- Adam :
  - Momentum + RMSPProp
  - Très rapide au début
  - Stabilité accrue

$$\Phi(w) = f(w) + \lambda \|w\|_1$$

- Norme  $L_1$  non dérivable
- Utilisation du proximal
- Promotion de la sparsité

$$\text{prox}_{\lambda \|\cdot\|_1}(v) = \text{soft-thresholding}(v)$$

$$(v_j - \lambda)_+ - (-v_j - \lambda)_+$$

- ISTA :

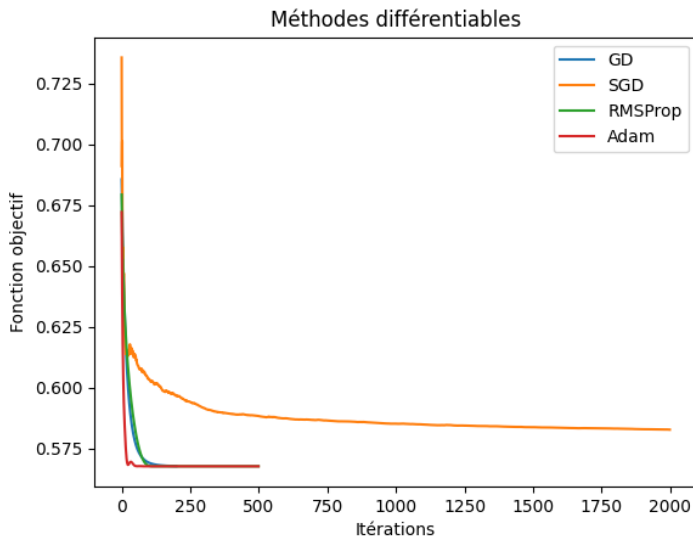
$$\mathcal{O}(1/k)$$

- FISTA (Nesterov) :

$$\mathcal{O}(1/k^2)$$

- Accélération significative observée

# Courbes Perte vs Temps



- Adam converge le plus vite initialement
- SGD plus bruité mais peu coûteux
- FISTA domine ISTA
- Impact clair du momentum



# Conclusion

- Validation théorique des chapitres 1 à 4
- Comparaison complète des méthodes
- Données réelles et résultats observables
- Bon compromis biais-variance via L1